Pakkimine

10IT · Sissejuhatus infotehnoloogiasse · 9. tund · konspekt

See konspekt selgitab kõik algusest peale ja seda saab lugeda ka tunnist puududes. Lahenda „Proovi ise“ kastid, vastused on lõpus. Veebilehel on **Pakkimislabor**, kus saad kõike päris failidega järele proovida. Konspekti lõpus on kirjas, mida tunnis samm-sammult teeme.

Pärast seda tundi oskad:
• pakkida ja lahti pakkida RLE-ga;
• arvutada, mitu korda andmemaht väheneb ja mitu protsenti säästsid;
• selgitada, millal sobib kadudeta ja millal kadudega pakkimine.

Poenimekiri

Sul on vaja poest 12 õuna tuua. Sa ei kirjuta paberile kaksteist korda „õun“, vaid „12 õuna“. Selle pisikese trikiga oledki avastanud pakkimise.

Pakkimine tähendab, et sama info kirjutatakse vähemate baitidega. Üks bait koosneb 8 bitist. Märgi salvestamiseks vajalik baitide arv sõltub kodeeringust: näiteks UTF-8 kodeeringus võtab a ühe baidi ja õ kaks baiti. 1 MB on 1 000 000 baiti.

Eelmises tunnis arvutasime, et 12-megapikslise pildi pakkimata RGB-andmed võtaksid 36 MB, aga pakitud fotofail võib olla näiteks 3 MB. Ilma pakkimiseta mahuks telefoni palju vähem pilte ja video vaatamine netist oleks palju raskem. Täna saad teada, kuidas see käib, ja proovid järele.

Pakkimisviis nr 1: loe järjest samad kokku

Mõtle pildile, kus iga piksel (pildi väikseim ruut) on kas valge või must. Eelmises tunnis piisas kahevärvilise pildi ühe piksli jaoks ühest bitist. Siin kasutame RLE õppimiseks lihtsustatud esitust: iga piksel on kirjas ühebaidise märgina V (valge) või M (must). Üks rida kümnest pikslist:

```
V V V V V M M M V V        10 pikslit = 10 baiti
```

Selle asemel, et iga piksel eraldi üles kirjutada, loeme kokku, mitu ühesugust on järjest: viis valget, kolm musta, kaks valget. Kirjutame `5V 3M 2V`. Meie mudelis salvestatakse korduste arv ühe baidina ja värvitähis teise baidina. Paare on kolm, nii et kokku 6 baiti. Kümne asemel! Ka paar `12V` võtab kaks baiti. Näidetes olevad tühikud on ainult lugemise hõlbustamiseks.



Sama rida: pakkimata 10 baiti, pakituna 6 baiti.

Seda viisi nimetatakse **RLE**-ks (ingl *run-length encoding*). Eesti keeles võiks öelda „järjendite pakkimine“, kus järjend on rida ühesuguseid asju.

Lahtipakkimine on sama lihtne: kirjuta iga paari järgi pikslid uuesti välja. `2M 3V` tähendab kaks musta ja kolm valget, ehk `MMVVV`. Tulemus on täpselt sama, mis enne pakkimist, midagi ei kadunud. See on **kadudeta** pakkimine.

Proovi ise 1. Paki rida `MMMMVVVVVV`. Mitu baiti see võtab? Paki lahti `2V 3M 1V`. Harjuta Pakkimislabori vahelehel **RLE**, seal kontrollib arvuti vastuse kohe ära.

Kui hästi see töötas?

Pakkimise tulemust mõõdetakse kahel viisil. Mõlemad arvutused põhinevad jagamisel.

```
Mitu korda väiksem?       enne : pärast
                          10 baiti : 5 baiti = 2 korda

Mitu protsenti säästsid?  (enne − pärast) : enne × 100
                          (10 − 5) : 10 × 100 = 50 %
```

Kui 36 MB-st saab 3 MB: 36 MB : 3 MB = 12 korda väiksem. Säästetud on (36 − 3) : 36 × 100 ≈ 92 %. Kui võrdled eri pikkusega faile, on protsent parem mõõt kui säästetud baitide arv.

Proovi ise 2. Fail oli 5 MB, pärast pakkimist 1 MB. Mitu korda väiksem ja mitu protsenti säästetud?

Aga mis siis, kui järjest ühesuguseid pole?

Proovi nüüd malelauda, kus värvid vahelduvad iga ruudu järel:



Kaheksa pikslit, kaheksa paari. Pakitud kuju on suurem kui algne!

Kaheksast baidist sai kuusteist. Andmemaht *kasvas* kaks korda. See pole programmiviga. RLE elab kordustest ja kui korduseid pole, pole ka millestki kokku hoida.

See on tähtis mõte, mis tuleb täna veel mitu korda tagasi: **ükski kadudeta pakkija ei suuda iga faili väiksemaks teha.**

Pakkimisviis nr 2: sõnastik

RLE aitab ainult siis, kui samad asjad on kohe üksteise kõrval. Tekstis on sageli teisiti. Vaata seda lauset. Selles näites loeme märke, sealhulgas tühikuid ja kirjavahemärke. See ei ole faili täpne baitide arv.

```
kass istub, kass sööb, kass magab          33 märki
```

Järjest ühesuguseid tähti siin pole, aga sõna „kass“ kordub. Teeme väikese sõnastiku: 1 tähendab sõna „kass“.

```
sõnastik: 1=kass                            6 märki
tekst:    1 istub, 1 sööb, 1 magab         24 märki
kokku                                      30 märki
```

Pane tähele, et sõnastik tuleb ka kaasa pakkida, muidu ei saa keegi teksti lahti pakkida. Seepärast võitsime siin ainult 3 märki. Pikas tekstis, kus sama sõna on sada korda, on võit palju suurem. Mõtle laulule, kus refrään kordub: piisab, kui refräänist on üks koopia ja mujale kirjutad „nüüd tuleb refrään“.

Sarnast ideed kasutavad levinud kadudeta vormingud gzip ja ZIP. Natuke kavalamalt küll: eraldi sõnastiku asemel võib seal olla kirjas „mine 16 märki tagasi ja kopeeri sealt 4 märki“. Idee on sama: ära kirjuta kaks korda seda, mis on juba olemas. Programmis või tekstis ei tohi ükski täht kaotsi minna, seega sobib siia just kadudeta pakkimine.

Proovi ise 3. Paki sõnastikuga lause `tere tere tere Mari`. Mitu märki oli enne ja mitu pärast, kui ka sõnastik kokku lugeda?

Miks juhuslikku asja on raske pakkida?

Kujuta ette, et pead sõbrale telefonis ette lugema tähed `xqf7kP2z`. Lühemalt seda öelda ei saa, pead kõik ükshaaval ära ütlema. Mustrit pole, nii et pole ka midagi lühendada.

Sarnane lugu on juba pakitud failiga. Juba pakitud failis on tavaliselt vähem lihtsalt ärakasutatavaid kordusi. Seepärast ei tee ZIP JPEG-pilti tavaliselt palju väiksemaks ja ZIP-i pakkimine teise ZIP-i sisse enamasti ei aita.

Pakitud andmetele lisandub ka vormingu lisainfo. Seetõttu võib väga lühike tekst pakkimisel hoopis suureneda. Seda näed vahelehel **gzip-labor**. Selles laboris pakib brauser teksti gzip-vormingus ja näitab baitide arvu enne ja pärast. ZIP on teine levinud pakkimisvorming.

Pakkimisviis nr 3: viska ära, mida silm kergesti ei näe

Foto on keerulisem. Fotol võib olla palju väikeseid värvierinevusi, mistõttu lihtne RLE ei pruugi hästi töötada. JPEG lähenebki teisest otsast: kas inimesel on vaja iga väikest erinevust?

Kujuta ette, et kirjeldad telefonis sõbrale pilti taevast. Sa ei hakka ütlema iga ruudu täpset värvi, vaid ütled: „see nurk on helesinine“. Sõber saab enam-vähem sama pildi. JPEG jagab pildi väikesteks ruutudeks (8 × 8 pikslit) ja lihtsustab igaühes väikeseid erinevusi.



Lihtsustatud näide väikeste heleduseerinevuste eemaldamisest; see ei näita JPEG-i täpset tööalgoritmi.

See on **kadudega** pakkimine. Infot läheb päriselt kaotsi ja seda ei saa kuidagi tagasi. Salvestamisel saad valida kvaliteedi: kõrgem kvaliteet tähendab vähem ära visatud infot ja tavaliselt suuremat faili.

Siit tuleb ka see, miks tekst JPEG-is võib halvasti välja näha. Teravate mustade tähtede ümber võib tekkida plekiline aura. Seepärast on ekraanipildi jaoks PNG sageli parem.

JPEG-pildi kvaliteet võib halveneda, kui pilti muudetakse ja seejärel uuesti JPEG-vormingus salvestatakse. Faili muutmata kopeerimine või saatmine selle kvaliteeti ei vähenda. Vaata seda vahelehel **JPEG-labor** nupuga „Salvesta uuesti“, mis lõikab pildilt iga kord serva ära ja salvestab uuesti.

Mida millal kasutada?

Asi	Vali	Miks
foto	JPEG	Väikesed kaod ei paista tavaliselt välja.
ekraanipilt, logo, joonis	PNG	Palju ühesugust värvi pikslit, teravad servad ei tohi plekiliseks minna.
tekst, kood, programmid	ZIP, gzip	Ükski märk ei tohi kaduda.
muusika	MP3, AAC	Kadudega: väike kadu jääb tavaliselt kõrvale märkamatuks.
juba pakitud fail	ära paki	Sellest ei tule tavaliselt palju kasu.

Mida tunnis teeme

1. **RLE käsitsi.** Ava Pakkimislaboris vaheleht RLE ja tee ülesanded läbi. Täida töölehe 1. ja 2. osa.
2. **Päris gzip.** Vahelehel gzip-labor on kolm nuppu: korduv tekst, tavaline tekst ja juhuslikud märgid. Vajuta kõiki, kirjuta tulemused töölehe 3. ossa ja kleebi kasti ka oma tekst.
3. **Päris JPEG.** Vahelehel JPEG-labor vali foto moodi pilt, seejärel logo moodi pilt ja liiguta kvaliteeti. Kirjuta suurused töölehe 4. ossa. Soovi korral proovi oma pildiga, see ei lahku su arvutist.
4. **Selgita.** Täida töölehe viimane osa, tee kodus lõpuni, mis jäi pooleli, ja saada tööleht ära. Ülesanne 5c on lisaülesanne.

Sõnastik

Sõna	Tähendus
andmemaht	mitu baiti andmed võtavad
pakkimine	sama info kirjutamine vähemate baitidega
kadudeta	lahti pakkides saad täpselt sama faili tagasi (PNG, ZIP, gzip)
kadudega	osa infot visatakse jäädavalt ära (JPEG, MP3)
RLE	pakkimine, mis loeb kokku, mitu ühesugust asja on järjest: 5V 3M
sõnastik	nimekiri korduvatest tükkidest, millele saab tekstis lühidalt viidata
ZIP, gzip	levinud kadudeta pakkimisvormingud
kvaliteet	JPEG-i seadistus: mida kõrgem, seda vähem infot visatakse ära

„Proovi ise“ vastused

1. `4M 6V`, kaks paari ehk 4 baiti. Lahti pakituna `VVMMMV`.
2. 5 : 1 = 5 korda väiksem. (5 − 1) : 5 × 100 = 80 % säästetud.
3. Enne 19 märki. Sõnastik `1=tere` on 6 märki ja tekst `1 1 1 Mari` on 10 märki, kokku 16.