

Tekst ja failimahud

10IT · Sissejuhatus infotehnoloogiasse · 3. tund · konspekt

Selle tunni suur mõte: arvutis ei ole tähti, pilte ega helisid. On ainult arvud ja kokkulepped selle kohta, mida need arvud tähendavad. Kui see lause on meeles, on kõik ülejäänu lihtsalt näited.

Meeldetuletus: bitt

Arvuti sees on miljardeid pisikesi lüliteid ja igaüks saab olla kas sees või väljas. Üks selline lüliti on **bitt**: sees on 1, väljas on 0. Eelmistes tundides nägid, et mitu bitti kõrvuti moodustavad kahendarvu, näiteks 1011 on kümnendsüsteemis $8 + 0 + 2 + 1 = 11$.

Mitu väärtust mahub?

Hakkame päris algusest. Ühe bitiga saab kirja panna kaks erinevat asja: 0 ja 1. Nagu lüliti: tuli põleb või ei põle.

Kahe bitiga on võimalusi juba neli: 00, 01, 10 ja 11. **Kolme bitiga** kaheksa, siin on kõik need välja kirjutatud:

Bitid	000	001	010	011	100	101	110	111
Arv	0	1	2	3	4	5	6	7

Märkad mustrit? Iga lisabitt **kahekordistab** võimaluste arvu, sest iga vana võimalus saab nüüd olla nii 0-ga kui ka 1-ga alguses. Nii kasvab see väga kiiresti:

Bitte	1	2	3	4	5	6	7	8	10	16
Väärtusi	2	4	8	16	32	64	128	256	1024	65 536

Matemaatikas kirjutatakse see lühidalt 2^n , kus n on bittide arv. See tähendab lihtsalt, et kahte korrutatakse iseendaga n korda: $2^3 = 2 \cdot 2 \cdot 2 = 8$.

Käega proovimiseks: tõsta üks käsi ja lepi kokku, et iga sõrm on bitt, püsti on 1 ja all on 0. Viie sõrmega saab näidata $2^5 = 32$ eri väärtust: nullist (kõik all) kuni 31-ni (kõik püsti).

Tähelepanu: väärtusi on alati ühe võrra rohkem kui suurim arv, sest ka null on väärtus. 8 bitti annab 256 väärtust, aga suurim arv on 255.

Tagurpidi: mitu bitti on vaja?

Sageli küsitakse vastupidi: mitu bitti on vaja, et kirja panna näiteks kõik arvud nullist sajani? Seda on 101 erinevat väärtust. Kahekordista, kuni jõuad vähemalt nii kaugele: 2, 4, 8, 16, 32, 64, 128. 64-st jääb puudu, 128 piisab. See oli seitsmes samm, seega on vaja **7 bitti**.

Bait

Kaheksa bitti koos on **bait**. Sinna mahub 256 eri väärtust, 0 kuni 255. Kaheksa sai standardiks 1964. aastal IBM-i arvutitega ja nii on see jäänud tänaseni: faili suurust mõõdetakse baitides.

Lugu, mis jääb meelde: mängus Pac-Man hoiti taseme numbrit ühes baidis. Kui mängija jõudis tasemele 256, ei mahtunud arv enam baiti ära ja pool ekraani täitus prahiga. Edasi mängida ei saanud. Seda kohta kutsutakse tänaseni *kill screen*'iks.

Arvutis ei ole tähti

Mäletad värvikoodi #FF0000? See on kolm arvu: 255, 0 ja 0. Miks see on punane? Vastus on igav ja väga tähtis: **sest nii lepiti kokku**. Keegi otsustas, et esimene arv tähendab punast, teine rohelist ja kolmas sinist.

Tähtedega on täpselt sama lugu. Arvuti ei tea, mis on „A“. Ta hoiab mälus ainult arvu ja kokkulepe ütleb, millise tähena seda ekraanil näidata.

ASCII: kõige vanem tähetabel

Kas oled lapsena kirjutanud salakirja, kus A = 1, B = 2, C = 3? Arvuti teeb täpselt sama, ainult tabel on teine. Kõige vanem ja tuntuim selline tabel on **ASCII**, kus A ei ole 1, vaid 65. Siin on kõik ASCII märgid, mida saab ekraanil näha:

Märk	Arv	Märk	Arv	Märk	Arv	Märk	Arv	Märk	Arv
tühik	32	3	51	F	70	Y	89	l	108
!	33	4	52	G	71	Z	90	m	109
"	34	5	53	H	72	[	91	n	110
#	35	6	54	I	73	\	92	o	111
\$	36	7	55	J	74	]	93	p	112
%	37	8	56	K	75	^	94	q	113
&	38	9	57	L	76	_	95	r	114
'	39	:	58	M	77	`	96	s	115
(	40	;	59	N	78	a	97	t	116
)	41	<	60	O	79	b	98	u	117
*	42	=	61	P	80	c	99	v	118
+	43	>	62	Q	81	d	100	w	119
,	44	?	63	R	82	e	101	x	120
-	45	@	64	S	83	f	102	y	121
.	46	A	65	T	84	g	103	z	122
/	47	B	66	U	85	h	104	{	123
0	48	C	67	V	86	i	105		124
1	49	D	68	W	87	j	106	}	125
2	50	E	69	X	88	k	107	~	126

Arvud 0 kuni 31 ja 127 on nähtamatud juhtmärgid, näiteks „uus rida“. Neid tabelis pole, sest ekraanile nad midagi ei joonista.

Kuidas tabelit lugeda

Arvudest tekstiks: otsi iga arv tabelist üles ja kirjuta selle kõrval olev märk. Näiteks 72 101 105: 72 on H, 101 on e, 105 on i. Kokku **Hei**.

Tekstist arvudeks: vastupidi. Sõna „Pall“: P on 80, a on 97, l on 108 ja teine l samuti 108. Kokku 80 97 108 108.

Suur ja väike täht on erinevad arvud. A on 65, a on 97. Kahendsüsteemis on need 01000001 ja 01100001: vahe on täpselt üks bitt. Väiketähed on alati 32 võrra suuremad.

Lõks: märk „5“ ei ole arv 5. ASCII-tabelis on märk „5“ hoopis arv 53. Kui kirjutad telefoni numbri, salvestatakse märgid, mitte arvud.

Aga kus on õ?

ASCII kasutab 7 bitti, seega mahub sinna $2^7 = 128$ märki. Tabeli pani 1963. aastal kokku Ameerika standardikomitee ja nende jaoks piisas inglise tähestikust. Õ, ä, ö ja ü sinna lihtsalt ei mahtunud.

Kui arvutid hakkasid kasutama kaheksandat bitti, tuli juurde veel 128 kohta. Probleem oli selles, et iga maa täitis need omamoodi. Ühes arvutis tähendas arv 245 „õ“-d, teises hoopis mõnda kreeka või vene tähte. Sama arv tähendas eri arvutis eri märki.

Tulemuste oled kindlasti näinud: vanas e-kirjas, filmi subtiitrites või Excelis avatud failis on täpitähtede asemel imelikud märgid:

Kirjutatud:	Tänan	Loetud:	TÃnan
Kirjutatud:	õun	Loetud:	Äpun

Nii juhtub, kui kirjutaja ja lugeja kasutavad eri kokkulepet. Baidid on samad, tabel on teine. Proovi veebilehe Tekstilaboris: kirjuta oma nimi ja vaata, mis sellest vale kokkuleppega saab.

Lahendus: Unicode

Unicode on üks ühine tabel kogu maailmale. Selles on üle 150 000 märgi: eesti täpitähed, kreeka ja vene tähed, hiina märgid, noodimärgid ja emojid. Igal märgil on oma number ja see number on igal pool sama. Esimesed 128 on täpselt samad mis ASCII-s, nii et vana tekst jäi kehtima.

Märk	Unicode'i number	Märkus
A	65	sama mis ASCII-s
õ	245	eesti täpitäht
π	960	kreeka täht pii
€	8364	euro märk
naerunägu (emoji)	128 512	emojid on tabeli lõpus

UTF-8: kuidas numbrid baitidesse panna

Arv 128 512 ei mahu ühte baiti. **UTF-8** on reegel, mis ütleb, mitu baiti iga märk võtab. Selle mõtlesid 1992. aastal välja kaks programmeerijat, legendi järgi restoranis paberist lauamati peal. Tänapäeval kasutab UTF-8-t üle 98% veebilehtedest.

Unicode'i number	Baite UTF-8-s	Näited
0 kuni 127	1	ladina tähed, numbrid, tühik, kirjavahemärgid (kõik ASCII)
128 kuni 2047	2	õ, ä, ö, ü, š, ž, kreeka ja vene tähed
2048 kuni 65 535	3	€, hiina ja jaapani märgid
üle 65 535	4	emojid

UTF-8 nutikus on selles, et vanad ASCII märgid võtavad endiselt ainult ühe baiti. Inglisekeelne tekst ei läinud suuremaks, eesti tekst läks natuke.

Märk ja bait ei ole sama asi

Nüüd tuleb tunni kõige tähtsam vahe. **Märk** on see, mida silm näeb: üks täht, number või tühik. **Bait** on see, palju see mälus ruumi võtab. ASCII märgi puhul on need samad, täpitähe puhul mitte.

Kuidas lugeda: kõigepealt loe märgid kokku. Siis lisa iga märgi eest üks bait ja iga täpitähe eest veel üks juurde.

Sõna	Märke	Baite	Miks
Tere!	5	5	kõik on ASCII märgid, igaüks 1 bait
oun	3	3	kõik ASCII
õun	3	4	õ võtab 2 baiti: 2 + 1 + 1
Tänan	5	6	ä võtab 2 baiti
Tšau	4	5	š võtab 2 baiti
öö	2	4	mõlemad ö-d võtavad 2 baiti

Kontrolltöös tuleb just selline ülesanne. Loe küsimus hoolikalt: kas küsitakse märke või baite?

Failimahud

Kui üks täht on üks bait, siis raamat on juba päris palju baite. Suuremate asjade jaoks on suuremad ühikud. Iga samm redelil on tuhat korda suurem:

Ühik	Lühend	Suurus	Mis sinna umbes mahub
bitt	b	üks 0 või 1	jah või ei
bait	B	8 bitti	üks ASCII täht
kilobait	KB	1000 baiti	lühike e-kiri
megabait	MB	1000 KB	raamat, üks foto, üks laul
gigabait	GB	1000 MB	film, sadu fotosid
terabait	TB	1000 GB	terve arvuti kõvaketas

Väike b ja suur B. b on bitt, B on bait. Internetikiirust mõõdetakse bittides (Mbit/s), faile baitides (MB). Kuna baidis on 8 bitti, jaga 8-ga: 100 Mbit/s ühendus laadib sekundis umbes 12,5 MB.

Et suurustest aimu saada, siin on mõned tüüpilised failid:

Mis	Umbes kui suur
lühike SMS	100 baiti
raamat tekstina (500 lk)	1 MB
telefonifoto (JPEG)	2–5 MB
laul MP3-na (4 minutit)	4 MB
tund HD-videot voogedastuses	3 GB
telefoni mälu	64–512 GB

Kolm arvutust

Nüüd paneme kõik kokku. Iga arvutus kasutab midagi, mida juba tead.

Raamat

Raamatus on 500 lehekülge ja igal leheküljel umbes 2000 märki. Märke kokku: $500 \cdot 2000 = 1\,000\,000$. Iga märk on umbes üks bait, seega 1 000 000 baiti ehk umbes **1 MB**. Terve raamat on väiksem kui üks telefonifoto!

Foto

12-megapiksline foto koosneb 12 miljonist pikslist. Iga piksel on üks värviline täpp ja selle värv on kolm baiti, täpselt nagu värvikoodis: punane, roheline, sinine. Kokku $12\,000\,000 \cdot 3$ baiti = 36 miljonit baiti ehk **36 MB**.

Video

Video on lihtsalt palju pilte järjest. Üks täis-HD kaader on $1920 \cdot 1080$ pikslit, igaüks kolm baiti: kokku umbes 6 MB. Sekundis näidatakse 30 kaadrit: $6 \cdot 30 = 180$ MB sekundis. Tunnis on 3600 sekundit: $180\,000 \approx$ **650–670 GB** tunnis. See on peaaegu terve kõvaketas ühe tunni video jaoks!

Aga minu telefonis on foto 3 MB?

Õige tähelepanek. Päris telefonifoto on 2–5 MB ja tunni videot saab vaadata ka mobiilse interneti pealt. Põhjus on **pakkimine**: faili tehakse väiksemaks. Pakkimist on kahte sorti.

- **Kadudeta pakkimine** (ZIP, PNG): fail tehakse väiksemaks nii, et midagi ei kao. Lahti pakkides saad täpselt sama faili tagasi. Tekstiga töötab see väga hästi.
- **Kadudega pakkimine** (JPEG, MP3, video): fail tehakse väiksemaks, visates ära detailid, mida silm või kõrv nagunii ei märka. Nii saab faili kümneid või isegi sadu kordi väiksemaks, aga ära visatud detaile enam tagasi ei saa. Mida rohkem pakid, seda kehvem pilt.

Proovi kodus: vaata, mitu fotot on su telefonis, ja korruta see 3 MB-ga. Siis kontrolli seadetest, kui palju fotod tegelikult ruumi võtavad. Kui lähedale jõudsid?

1000 või 1024?

Poes müüakse 1 TB kõvaketast, aga arvuti näitab ainult umbes 931 GB. Kas keegi varastas midagi? Ei. Poes loetakse tuhandetes: 1 TB = 1 000 000 000 000 baiti. Arvuti aga loeb tihti 1024-kaupa, sest $1024 = 2^{10}$ on kahendsüsteemis ümmargune arv. Kui jagada samad baidid 1024-kaupa, tuleb välja umbes 931.

Kontrolltöös on mõlemad arvestused õiged, kui kasutad ühte neist järjekindlalt. Selles konspektis loeme lihtsuse mõttes tuhandetes.

Näidisülesanded lahendustega

Kontrolltöö ülesanded on sellised. Proovi kõigepealt ise, siis vaata lahendust.

Ülesanne. Mitu erinevat väärtust mahub 6 bitti?

Kahekordistame kuus korda: 2, 4, 8, 16, 32, 64. **Vastus: 64.**

Ülesanne. Mitu bitti on vähemalt vaja, et kirjutada arvud 0 kuni 100?

Väärtusi on 101. 6 bitti annab 64, sellest jääb puudu. 7 bitti annab 128, sellest piisab. **Vastus: 7 bitti.**

Ülesanne. Mis sõna on 83 117 112 112?

Tabelist: 83 on S, 117 on u, 112 on p. **Vastus: Supp.**

Ülesanne. Mitu märki ja mitu baiti (UTF-8) on sõnas „Tšau“?

Märke on 4: T, š, a, u. Baite: T, a ja u võtavad ühe, š kaks. $1 + 2 + 1 + 1 = 5$. **Vastus: 4 märki, 5 baiti.**

Ülesanne. Kui suur on 16-megapiksline foto pakkimata?

16 miljonit pikslit · 3 baiti = 48 miljonit baiti. **Vastus: 48 MB.**

Ülesanne. Mitu 5 MB laulu mahub 32 GB telefoni?

32 GB = 32 000 MB. $32\,000 : 5 = 6400$. **Vastus: umbes 6400 laulu.**

Ülesanne. Värvikood on #800080. Mis värv see on?

Punane 80 = $8 \cdot 16 = 128$, roheline 00 = 0, sinine 80 = 128. Pool punast ja pool sinist annab lilla.

Ülesanne. Internetiühendus on 100 Mbit/s. Kui kaua kulub 1 GB filmi alla laadimiseks?

$100 \text{ Mbit/s} : 8 = 12,5 \text{ MB sekundis}$. 1 GB = 1000 MB. $1000 : 12,5 = 80$. **Vastus: umbes 80 sekundit.**

Meelespea

Meeles pidada	
n bitti	mahutab $2 \cdot 2 \cdot \dots \cdot 2$ (n korda) väärtust
1 bait	8 bitti, 256 väärtust, suurim arv 255
ASCII	128 märki (7 bitti), A = 65, a = 97, tühik = 32
UTF-8	ASCII märk 1 bait, täpitäht 2 baiti, € 3, emoji 4
märk ≠ bait	„öun“: 3 märki, 4 baiti
ühikud	B → KB → MB → GB → TB, iga samm · 1000
b ja B	bitt ja bait: 8 b = 1 B, Mbit/s jagatud 8-ga = MB/s
foto	megapikslid · 3 baiti = MB (pakkimata)
1000 ja 1024	1 TB ketas näitab arvutis umbes 931 GB

Sõnastik

Mõiste	Lihtsalt öeldes
bitt	üks 0 või 1, kõige väiksem andmetükk
bait	8 bitti, mahutab 256 eri väärtust
märk	üks täht, number, tühik või emoji: see, mida silm näeb
kokkulepe	tabel, mis ütleb, millist märki iga arv tähendab
ASCII	1963. aasta tabel 128 märgiga: ladina tähed, numbrid ja märgid
Unicode	ühine tabel kogu maailma märkidele, üle 150 000 märgi
UTF-8	viis Unicode'i numbrid baitidesse kirjutada
piksel	üks värviline täpp pildil
megapiksel	miljon pikslit
pakkimine	faili väiksemaks tegemine, näiteks ZIP, JPEG või MP3

Kontrolli ennast

- Mitu väärtust mahub 4 bitti? Aga 8 bitti? Mis on 8 bitiga suurim arv?
- Miks on #FF0000 punane?
- Mis sõna on 72 101 105? Kirjuta sõna „Pall“ ASCII-arvudena.
- Miks on märk „5“ ja arv 5 erinevad asjad?
- Miks õ ASCII-sse ära ei mahtunud ja mis juhtub, kui kirjutaja ja lugeja kasutavad eri tabelit?
- Mitu märki ja mitu baiti on sõnas „õun“?
- Umbes kui suur on 500-leheküljeline raamat? Aga 12-megapiksline foto pakkimata?
- Mis vahe on kadudeta ja kadudega pakkimisel?
- Miks näitab 1 TB ketas arvutis ainult umbes 931 GB?